

1. 流形假设

- 高维空间的图像数据，不会零散的分布在整個高维空间，而是依附在一个低维的流形上。这个流形是数据的专属区域，只包含数据的核心信息，比如物体的形状，颜色，剔除了高维的冗余和噪声。
- 图像数据看起来是高维的，但本质上是低维的，像高维空间卷起来的一张低维纸，所有数据都落在这张纸上。

2. 传统扩散模型的弊端

- epsilon-pred, 预测epsilon的方法 (sd类)，在高维下会失效，在预测整个高维空间中的数据分布时，模型需要记住每个patch的特征，需要广大的网络宽度与冗余参数；
- v-pred, 预测数据噪声混合流速，但带噪量v需要横跨整个高维空间，模型需要学习的范式更加复杂，也需要高容量，训练难度也高；

3. JiT 贡献

- JiT直接预测干净数据 (x-prediction)
- 无需模型记高维噪声细节；
- 从带噪输入筛选低维干净数据特征；
- 降低模型容量需求，避免高维空间维度灾难；
- 契合精准提取核心信息逻辑；

4. JiT - 核心预测目标 (x- prediction)

- 输入带噪数据 z_t ($z_t = t \cdot x + (1-t) \cdot \epsilon$), 模型直接输出干净数据预测值 x_{θ} ($x_{\theta} = \text{net}_{\theta}(z_t, t)$), 无需反推；
- 依流型假设，模型筛流形核心特征；
- 隐藏层低于 patch维仍精准预测；
- 用 v-loss优化， x_{θ} 转 v_{θ} 保稳定；
- 不改变直接预测 x 逻辑，免复杂加权；

5. JiT - 极简架构设计 (大 patch Transformer)

- 图像划非重叠大 patch，降序列长度；
- 256 x 256 用16x16 patch (长256)；
- 512 x 512 用32x32 patch (长256)；
- 核心组件仅线性嵌入，无额外模块；
- 无Tokenizer、预训练等，像素端到端训；
- 大 patch 保留局部语义完整性，减计算量，分辨率不影响长度；
- 1024x1024 与 256x256 计算量相当

6. JiT - 瓶颈嵌入；

- patch 嵌入层加“降维 + 升维”线性瓶颈；
- 高维patch 先降维 d' ，再升维至隐藏层（将高维patch（如16x16x3=768）先降低维的 d' （可低至16维），再升到transformer的隐藏层的维度）；
- JiT用logit-normal采样t调噪声水平；
- 噪声调度最优 $\mu = -0.8$ ，衡稳与质量；
- 瓶颈促进模型学习低维特征，契合流型假设；
- 瓶颈 32 - 512 维度时，FID提升1.3
- 瓶颈低至 16 维，无性能退化；

7. 训练与推理

- 训练流程；
 - 核心步骤

采样 $t \rightarrow$ 生成 $z_t = t \cdot x + (1 - t) \cdot \text{epsilon}$ \rightarrow 模型输出 x_{theta} \rightarrow 计算 $v_{\text{theta}} = (x_{\text{theta}} - z_t)/(1 - t)$
 \rightarrow v -loss ($L = E_{t,x,\text{epsilon}} \| v_{\text{theta}} - v \|^2$) 优化 \rightarrow 更新参数
 - 组件状态

Transformer权重可训练, patch嵌入层 (linear patch embedding) /位置编码 (positional embedding) 参数固定;
 - 关键操作

含 v -loss计算与梯度反向传播更新 (更新Transformer核心权重与线性预测头权重)
- 推理流程
 - 核心步骤

初始化 z_0 (噪声, $z_0 \sim N(0, I)$) \rightarrow t 从0到1迭代 \rightarrow 模型输出 x_{theta} \rightarrow 计算 $v_{\text{theta}} = (x_{\text{theta}} - z_t)/(1-t)$
 \rightarrow ODE求解 $z_{t+\text{delta } t} \rightarrow t = 1$ 时输出 x_{theta}
 - 组件状态

所有组件 (Transformer、patch 嵌入层、位置编码、线性预测头) 权重固定, 仅执行前向计算
 - 关键操作

含50步Heun ODE求解 ($d z_t / dt = v_{\text{theta}}(z_t, t)$), 保证生成平滑;